

ارزیابی و پایش مدل‌های زبانی

LLM Evaluation & Observability

طراحی روند ارزیابی و پایش کاربردهای مبتنی بر مدل‌های زبانی؛ شامل مجموعه‌داده و معیارهای ارزیابی، داوری با مدل زبانی، ارزیابی RAG و ایجنت‌ها، ردگیری و پایش عملیاتی.

سطح دوره	مدت پیشنهادی	بخش و درس	شیوه‌ی برگزاری
متوسط	۳ روز (۲۴ ساعت)	۹ بخش، ۴۱ درس	حضور یی یا آنلاین

— آنچه شرکت‌کنندگان می‌آموزند

- توضیح اینکه چرا «ظاهراً درست کار می‌کند» دلیلی بر کارکرد درست یک قابلیت هوش مصنوعی نیست
- ساخت مجموعه‌داده‌ی مرجع که بازتاب استفاده‌ی واقعی باشد
- انتخاب میان معیارهای قطعی، مبتنی بر پاسخ مرجع و داوری با مدل زبانی
- ارزیابی تخصصی جریان‌های RAG و ایجنت‌های ابزارمحور
- ردگیری، پایش و محافظت از اپلیکیشن مبتنی بر مدل زبانی در محیط عملیاتی

پیش‌نیازها

- تسلط بر پایتون
- تجربه‌ی ساخت یا کار روی یک اپلیکیشن مبتنی بر مدل زبانی؛ این دوره ارزیابی آن را آموزش می‌دهد، نه ساخت اولین اپلیکیشن
- دسترسی به API یک مدل زبانی برای تمرین‌های عملی

ابزارها و فناوری‌ها

Pydantic Anthropic SDK (Claude)
scikit-learn ROUGE & NLTK

پروژه‌ی عملی

سامانه‌ی ارزیابی و پایش برای یک اپلیکیشن مبتنی بر مدل زبانی

۵ درس	۱ چرا ارزیابی اهمیت دارد	۱. دام «ظاهراً درست است» ۲. ارزیابی آفلاین در برابر آنلاین ۳. نگرش ارزیابی‌محور ۴. چه چیزی را بسنجیم: ابعاد کیفیت ۵. پروژه‌ی راهنمادار: اولین سامانه‌ی ارزیابی
۵ درس	۲ ساخت مجموعه‌داده‌ی ارزیابی	۱. مجموعه‌ی مرجع: ویژگی‌های یک مجموعه‌داده‌ی ارزیابی خوب ۲. نوشتن دستی موارد آزمون ۳. از گزارش‌های عملیاتی تا مجموعه‌ی آزمون ۴. پوشش، تفکیک و پاکیزگی مجموعه‌داده ۵. پروژه‌ی راهنمادار: ساخت مجموعه‌ی مرجع برای Docent
۵ درس	۳ معیارهای قطعی و مبتنی بر پاسخ مرجع	۱. تطابق دقیق و یکسان‌سازی ۲. F1 در سطح توکن و معیارهای هم‌پوشانی ۳. معیارهای BLEU، ROUGE و N-gram ۴. بررسی خروجی ساختاریافته و Schema ۵. پروژه‌ی راهنمادار: کارنامه‌ی معیارهای مرجع
۵ درس	۴ داوری با مدل زبانی (LLM-as-Judge)	۱. چرا و چه زمانی از مدل زبانی به‌عنوان داور استفاده کنیم ۲. امتیازدهی مستقیم با سنجه‌نامه ۳. مقایسه‌ی دوبه‌دو و ترجیح ۴. واسنجی داور و اعتماد به آن ۵. پروژه‌ی راهنمادار: داور واسنجی‌شده برای Docent
۵ درس	۵ ارزیابی RAG	۱. مسئله‌ی ارزیابی RAG: دو سامانه در یک سامانه ۲. معیارهای بازایی: Precision، Recall، MRR و NDCG ۳. وفاداری به منبع و مستندبودن پاسخ ۴. مرتبطبودن پاسخ و کیفیت زمینه ۵. پروژه‌ی راهنمادار: ارزیابی کامل یک RAG
۵ درس	۶ ارزیابی ایجنت‌ها و به‌کارگیری ابزار	۱. چرا ارزیابی ایجنت‌ها دشوارتر است ۲. معیارهای موفقیت در انجام وظیفه و نتیجه ۳. درستی فراخوانی ابزار ۴. ارزیابی مسیر حرکت ایجنت ۵. پروژه‌ی راهنمادار: ارزیابی نسخه‌ی ایجنتیک Docent

۷ پایش پذیری و ردگیری

۵ درس

۱. از ارزیابی تا پایش پذیری
۲. ثبت ساختاریافتهی فراخوانی های مدل
۳. Span و Trace: دنبال کردن یک درخواست
۴. حسابرسی هزینه، تأخیر و توکن
۵. پروژهی راهنمادار: ابزارگذاری Docent برای پایش

۸ پایش در محیط عملیاتی و سازوکارهای محافظتی

۵ درس

۱. پایش در محیط عملیاتی: داشبورد و هشدار
۲. تشخیص رانش و افت عملکرد
۳. آزمون پسرقت پرامپت و مدل در CI
۴. سازوکارهای محافظتی و بازخورد انسانی
۵. پروژهی راهنمادار: سامانهی پایش و محافظت

۹ پروژهی پایانی

۱ درس

۱. پروژهی راهنمادار: سامانهی کامل ارزیابی و پایش

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/contact

سرفصل، مدت، سطح و تمرین های دوره بر اساس نیاز تیم شما تنظیم می شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.