

ارزیابی و پایش مدل های زبانی

LLM Evaluation & Observability

به جای حدس زدن درباره ی کارکرد اپلیکیشن مبتنی بر مدل زبانی، یک روند واقعی ارزیابی و پایش بسازید: مجموعه داده ی ارزیابی، معیارها، داوری با مدل زبانی، ارزیابی RAG و ایجنت ها، ردگیری و پایش در محیط عملیاتی، با تمرین عملی در پایتون.

شیوه ی برگزاری	تعداد درس ها	تعداد بخش ها	سطح دوره
حضوری یا آنلاین	۴۱ درس	۹ بخش	متوسط

— آنچه شرکت کنندگان می آموزند

- توضیح اینکه چرا «ظاهراً درست کار می کند» دلیلی بر کارکرد درست یک قابلیت هوش مصنوعی نیست
- ساخت مجموعه داده ی مرجع که بازتاب استفاده ی واقعی باشد
- انتخاب میان معیارهای قطعی، مبتنی بر پاسخ مرجع و داوری با مدل زبانی
- ارزیابی تخصصی جریان های RAG و ایجنت های ابزارمحور
- ردگیری، پایش و محافظت از اپلیکیشن مبتنی بر مدل زبانی در محیط عملیاتی

پیش نیازها

- تسلط بر پایتون
- تجربه ی ساخت یا کار روی یک اپلیکیشن مبتنی بر مدل زبانی؛ این دوره ارزیابی آن را آموزش می دهد، نه ساخت اولین اپلیکیشن
- دسترسی به API یک مدل زبانی برای تمرین های عملی

ابزارها و فناوری ها

Pydantic Anthropic SDK (Claude)
scikit-learn ROUGE & NLTK

پروژه ی عملی

سامانه ی ارزیابی و پایش برای یک اپلیکیشن مبتنی بر مدل زبانی

۵ درس	۱ چرا ارزیابی اهمیت دارد
۴. چه چیزی را بسنجیم: ابعاد کیفیت	۱. دام «ظاهراً درست است»
۵. پروژه‌ی راهنمادار: اولین سامانه‌ی ارزیابی	۲. ارزیابی آفلاین در برابر آنلاین
	۳. نگرش ارزیابی‌محور
۵ درس	۲ ساخت مجموعه‌داده‌ی ارزیابی
۴. پوشش، تفکیک و پاکیزگی مجموعه‌داده	۱. مجموعه‌ی مرجع: ویژگی‌های یک مجموعه‌داده‌ی ارزیابی خوب
۵. پروژه‌ی راهنمادار: ساخت مجموعه‌ی مرجع برای Docent	۲. نوشتن دستی موارد آزمون
	۳. از گزارش‌های عملیاتی تا مجموعه‌ی آزمون
۵ درس	۳ معیارهای قطعی و مبتنی بر پاسخ مرجع
۴. بررسی خروجی ساختاریافته و Schema	۱. تطابق دقیق و یکسان‌سازی
۵. پروژه‌ی راهنمادار: کارنامه‌ی معیارهای مرجع	۲. F1 در سطح توکن و معیارهای هم‌پوشانی
	۳. معیارهای BLEU، ROUGE و N-gram
۵ درس	۴ داوری با مدل زبانی (LLM-as-Judge)
۳. مقایسه‌ی دوبه‌دو و ترجیح	۱. چرا و چه زمانی از مدل زبانی به‌عنوان داور استفاده کنیم
۴. واسنجی داور و اعتماد به آن	۲. امتیازدهی مستقیم با سنجه‌نامه
۵. پروژه‌ی راهنمادار: داور واسنجی‌شده برای Docent	
۵ درس	۵ ارزیابی RAG
۳. وفاداری به منبع و مستندبودن پاسخ	۱. مسئله‌ی ارزیابی RAG: دو سامانه در یک سامانه
۴. مرتبطبودن پاسخ و کیفیت زمینه	۲. معیارهای ارزیابی: Precision، Recall، MRR و NDCG
۵. پروژه‌ی راهنمادار: ارزیابی کامل یک RAG	
۵ درس	۶ ارزیابی ایجنت‌ها و به‌کارگیری ابزار
۴. ارزیابی مسیر حرکت ایجنت	۱. چرا ارزیابی ایجنت‌ها دشوارتر است
۵. پروژه‌ی راهنمادار: ارزیابی نسخه‌ی ایجنتیک Docent	۲. معیارهای موفقیت در انجام وظیفه و نتیجه‌ی درستی فراخوانی ابزار
	۳. درستی فراخوانی ابزار

۷ پایش پذیری و ردگیری

۵ درس

۱. از ارزیابی تا پایش پذیری
۲. ثبت ساختاریافته‌ی فراخوانی‌های مدل
۳. Span و Trace: دنبال کردن یک درخواست
۴. حسابرسی هزینه، تأخیر و توکن
۵. پروژه‌ی راهنمادار: ابزارگذاری Docent برای پایش

۸ پایش در محیط عملیاتی و سازوکارهای محافظتی

۵ درس

۱. پایش در محیط عملیاتی: داشبورد و هشدار
۲. تشخیص رانش و افت عملکرد
۳. آزمون پسرقت پرامپت و مدل در CI
۴. سازوکارهای محافظتی و بازخورد انسانی
۵. پروژه‌ی راهنمادار: سامانه‌ی پایش و محافظت

۹ پروژه‌ی پایانی

۱ درس

۱. پروژه‌ی راهنمادار: سامانه‌ی کامل ارزیابی و پایش

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/contact

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.