



سرفصل دوره‌ی آموزشی

ارزیابی و پایش مدل‌های زبانی

LLM Evaluation & Observability

به‌جای حدس‌زدن درباره‌ی کارکرد اپلیکیشن مبتنی بر مدل زبانی، یک روند واقعی ارزیابی و پایش بسازید: مجموعه‌داده‌ی ارزیابی، معیارها، داوری با مدل زبانی، ارزیابی RAG و ایجنت‌ها، ردگیری و پایش در محیط عملیاتی، با تمرین عملی در پایتون.

سطح دوره	تعداد بخش‌ها	تعداد درس‌ها	شیوه‌ی برگزاری
متوسط	۹ بخش	۴۱ درس	حضوری یا آنلاین

پیش‌نیازها

- تسلط بر پایتون
- تجربه‌ی ساخت یا کار روی یک اپلیکیشن مبتنی بر مدل زبانی؛ این دوره ارزیابی آن را آموزش می‌دهد، نه ساخت اولین اپلیکیشن
- دسترسی به API یک مدل زبانی برای تمرین‌های عملی

ابزارها و فناوری‌ها

Pydantic Anthropic SDK (Claude)
scikit-learn ROUGE & NLTK

پروژه‌ی عملی

سامانه‌ی ارزیابی و پایش برای یک اپلیکیشن مبتنی بر مدل زبانی

— آنچه شرکت‌کنندگان می‌آموزند

- ◆ توضیح اینکه چرا «ظاهراً درست کار می‌کند» دلیلی بر کارکرد درست یک قابلیت هوش مصنوعی نیست
- ◆ ساخت مجموعه‌داده‌ی مرجع که بازتاب استفاده‌ی واقعی باشد
- ◆ انتخاب میان معیارهای قطعی، مبتنی بر پاسخ مرجع و داوری با مدل زبانی
- ◆ ارزیابی تخصصی جریان‌های RAG و ایجنت‌های ابزارمحور
- ◆ ردگیری، پایش و محافظت از اپلیکیشن مبتنی بر مدل زبانی در محیط عملیاتی

۵ درس	۱ چرا ارزیابی اهمیت دارد
۴. چه چیزی را بسنجیم: ابعاد کیفیت	۱. دام «ظاهراً درست است»
۵. پروژه‌ی راهنمادار: اولین سامانه‌ی ارزیابی	۲. ارزیابی آفلاین در برابر آنلاین
	۳. نگرش ارزیابی‌محور
۵ درس	۲ ساخت مجموعه‌داده‌ی ارزیابی
۴. پوشش، تفکیک و پاکیزگی مجموعه‌داده	۱. مجموعه‌ی مرجع: ویژگی‌های یک مجموعه‌داده‌ی ارزیابی خوب
۵. پروژه‌ی راهنمادار: ساخت مجموعه‌ی مرجع برای Docent	۲. نوشتن دستی موارد آزمون
	۳. از گزارش‌های عملیاتی تا مجموعه‌ی آزمون
۵ درس	۳ معیارهای قطعی و مبتنی بر پاسخ مرجع
۴. بررسی خروجی ساختاریافته و Schema	۱. تطابق دقیق و یکسان‌سازی
۵. پروژه‌ی راهنمادار: کارنامه‌ی معیارهای مرجع	۲. F1 در سطح توکن و معیارهای هم‌پوشانی
	۳. معیارهای BLEU، ROUGE و N-gram
۵ درس	۴ داوری با مدل زبانی (LLM-as-Judge)
۳. مقایسه‌ی دوبه‌دو و ترجیح	۱. چرا و چه زمانی از مدل زبانی به‌عنوان داور استفاده کنیم
۴. واسنجی داور و اعتماد به آن	۲. امتیازدهی مستقیم با سنجه‌نامه
۵. پروژه‌ی راهنمادار: داور واسنجی‌شده برای Docent	
۵ درس	۵ ارزیابی RAG
۳. وفاداری به منبع و مستندبودن پاسخ	۱. مسئله‌ی ارزیابی RAG: دو سامانه در یک سامانه
۴. مرتبطبودن پاسخ و کیفیت زمینه	۲. معیارهای ارزیابی: Precision، Recall، MRR و NDCG
۵. پروژه‌ی راهنمادار: ارزیابی کامل یک RAG	
۵ درس	۶ ارزیابی ایجنت‌ها و به‌کارگیری ابزار
۴. ارزیابی مسیر حرکت ایجنت	۱. چرا ارزیابی ایجنت‌ها دشوارتر است
۵. پروژه‌ی راهنمادار: ارزیابی نسخه‌ی ایجنتیک Docent	۲. معیارهای موفقیت در انجام وظیفه و نتیجه‌ی درستی فراخوانی ابزار
	۳. درستی فراخوانی ابزار

۷ پایش‌پذیری و ردگیری

۵ درس

۱. از ارزیابی تا پایش‌پذیری
۲. ثبت ساختاریافته‌ی فراخوانی‌های مدل
۳. Span و Trace: دنبال کردن یک درخواست
۴. حسابرسی هزینه، تأخیر و توکن
۵. پروژه‌ی راهنمادار: ابزارگذاری Docent برای پایش

۸ پایش در محیط عملیاتی و سازوکارهای محافظتی

۵ درس

۱. پایش در محیط عملیاتی: داشبورد و هشدار
۲. تشخیص رانش و افت عملکرد
۳. آزمون پسرفت پرامپت و مدل در CI
۴. سازوکارهای محافظتی و بازخورد انسانی
۵. پروژه‌ی راهنمادار: سامانه‌ی پایش و محافظت

۹ پروژه‌ی پایانی

۱ درس

۱. پروژه‌ی راهنمادار: سامانه‌ی کامل ارزیابی و پایش

برگزاری اختصاصی برای سازمان شما

lotfinejad.ir/consultation

سرفصل، مدت، سطح و تمرین‌های این دوره بر اساس نیاز تیم شما تنظیم می‌شود. آموزش به زبان فارسی و به صورت حضوری یا آنلاین برگزار می‌شود.