

ارزیابی و پایش مدل های زبانی

LLM Evaluation & Observability

به جای حدس زدن درباره ی کارکرد اپلیکیشن مبتنی بر مدل زبانی، یک روند واقعی ارزیابی و پایش بسازید: مجموعه داده ی ارزیابی، معیارها، داوری با مدل زبانی، ارزیابی RAG و ایجنت ها، ردگیری و پایش در محیط عملیاتی، با تمرین عملی در پایتون.

شیوه ی برگزاری	تعداد درس ها	تعداد بخش ها	سطح دوره
حضوری یا آنلاین	۴۱ درس	۹ بخش	متوسط

— آنچه شرکت کنندگان می آموزند

- توضیح اینکه چرا «ظاهراً درست کار می کند» دلیلی بر کارکرد درست یک قابلیت هوش مصنوعی نیست
- ساخت مجموعه داده ی مرجع که بازتاب استفاده ی واقعی باشد
- انتخاب میان معیارهای قطعی، مبتنی بر پاسخ مرجع و داوری با مدل زبانی
- ارزیابی تخصصی جریان های RAG و ایجنت های ابزارمحور
- ردگیری، پایش و محافظت از اپلیکیشن مبتنی بر مدل زبانی در محیط عملیاتی

پیش نیازها

- تسلط بر پایتون
- تجربه ی ساخت یا کار روی یک اپلیکیشن مبتنی بر مدل زبانی؛ این دوره ارزیابی آن را آموزش می دهد، نه ساخت اولین اپلیکیشن
- دسترسی به API یک مدل زبانی برای تمرین های عملی

ابزارها و فناوری ها

Pydantic Anthropic SDK (Claude)
scikit-learn ROUGE & NLTK

پروژه ی عملی

سامانه ی ارزیابی و پایش برای یک اپلیکیشن مبتنی بر مدل زبانی

۵ درس	۱ چرا ارزیابی اهمیت دارد	۱. دام «ظاهراً درست است» ۲. ارزیابی آفلاین در برابر آنلاین ۳. نگرش ارزیابی محور ۴. چه چیزی را بسنجیم: ابعاد کیفیت ۵. پروژه‌ی راهنمادار: اولین سامانه‌ی ارزیابی
۵ درس	۲ ساخت مجموعه داده‌ی ارزیابی	۱. مجموعه‌ی مرجع: ویژگی‌های یک مجموعه داده‌ی ارزیابی خوب ۲. نوشتن دستی موارد آزمون ۳. از گزارش‌های عملیاتی تا مجموعه‌ی آزمون ۴. پوشش، تفکیک و پاکیزگی مجموعه داده ۵. پروژه‌ی راهنمادار: ساخت مجموعه‌ی مرجع برای Docent
۵ درس	۳ معیارهای قطعی و مبتنی بر پاسخ مرجع	۱. تطابق دقیق و یکسان‌سازی ۲. F1 در سطح توکن و معیارهای هم‌پوشانی ۳. معیارهای BLEU، ROUGE و N-gram ۴. بررسی خروجی ساختاریافته و Schema ۵. پروژه‌ی راهنمادار: کارنامه‌ی معیارهای مرجع
۵ درس	۴ داوری با مدل زبانی (LLM-as-Judge)	۱. چرا و چه زمانی از مدل زبانی به عنوان داور استفاده کنیم ۲. امتیازدهی مستقیم با سنجه‌نامه ۳. مقایسه‌ی دوبه‌دو و ترجیح ۴. واسنجی داور و اعتماد به آن ۵. پروژه‌ی راهنمادار: داور واسنجی‌شده برای Docent
۵ درس	۵ ارزیابی RAG	۱. مسئله‌ی ارزیابی RAG: دو سامانه در یک سامانه ۲. معیارهای بازیابی: Precision، Recall، MRR و NDCG ۳. وفاداری به منبع و مستندبودن پاسخ ۴. مرتبطبودن پاسخ و کیفیت زمینه ۵. پروژه‌ی راهنمادار: ارزیابی کامل یک RAG
۵ درس	۶ ارزیابی ایجنت‌ها و به‌کارگیری ابزار	۱. چرا ارزیابی ایجنت‌ها دشوارتر است ۲. معیارهای موفقیت در انجام وظیفه و نتیجه ۳. درستی فراخوانی ابزار ۴. ارزیابی مسیر حرکت ایجنت ۵. پروژه‌ی راهنمادار: ارزیابی نسخه‌ی ایجنتیک Docent

۷ پایش پذیری و ردگیری

۵ درس

۱. از ارزیابی تا پایش پذیری
۲. ثبت ساختاریافته‌ی فراخوانی‌های مدل
۳. Span و Trace: دنبال کردن یک درخواست
۴. حسابرسی هزینه، تأخیر و توکن
۵. پروژه‌ی راهنمادار: ابزارگذاری Docent برای پایش

۸ پایش در محیط عملیاتی و سازوکارهای محافظتی

۵ درس

۱. پایش در محیط عملیاتی: داشبورد و هشدار
۲. تشخیص رانش و افت عملکرد
۳. آزمون پسرقت پرامپت و مدل در CI
۴. سازوکارهای محافظتی و بازخورد انسانی
۵. پروژه‌ی راهنمادار: سامانه‌ی پایش و محافظت

۹ پروژه‌ی پایانی

۱ درس

۱. پروژه‌ی راهنمادار: سامانه‌ی کامل ارزیابی و پایش

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/contact

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.