

پردازش کلان داده با PySpark

PySpark for Data Engineering

یادگیری عملی Apache Spark روی رایانه‌ی شخصی: منطق Spark در Driver، Executor و طرح‌های اجرای Lazy؛ DataFrame و Spark SQL روی ده میلیون سفر واقعی تاکسی؛ طرح اجرا، پارتیشن، Shuffle و کش؛ و یک جریان ETL در قالب محیط عملیاتی با Schema، کنترل کیفیت و ثبت رویداد.

سطح دوره	تعداد بخش‌ها	تعداد درس‌ها	شیوه‌ی برگزاری
متوسط	۸ بخش	۳۶ درس	حضوری یا آنلاین

پیش‌نیازها

- تسلط بر پایتون و pandas
- بهتر است پس از دوره‌ی «پایتون مقیاس‌پذیر برای مهندسی داده» گذرانده شود
- رایانه‌ای که بتواند Spark را به صورت محلی اجرا کند؛ نیازی به خوشه یا حساب ابری نیست

ابزارها و فناوری‌ها

pandas

PySpark (حالت محلی)

PyArrow

پروژه‌ی عملی

جریان کامل ETL با Spark روی داده‌های واقعی تاکسی نیویورک

— آنچه شرکت‌کنندگان می‌آموزند

- ◆ توضیح نقش واقعی Driver، Executor و طرح اجرای Lazy
- ◆ کار با DataFrame و Spark SQL روی ده میلیون رکورد واقعی
- ◆ خواندن طرح اجرا و کنترل پارتیشن‌ها، Shuffle و کش
- ◆ ساخت جریان ETL در قالب محیط عملیاتی با کنترل کیفیت و ثبت رویداد

۵ درس	۱ چرا پردازش توزیع‌شده؟
۴. Spark چه زمانی برتری دارد (و چه زمانی نه)	۱. سقف توان یک رایانه
۵. پروژه‌ی راهنمادار: داده‌ی یک فصل در Spark	۲. Driver، Executor و حالت محلی
	۳. اولین SparkSession
۵ درس	۲ Lazy RDD، SparkSession و ارزیابی
۴. تغییرناپذیری و تبارنامه‌ی داده	۱. تبدیل‌ها در برابر اقدام‌ها
۵. پروژه‌ی راهنمادار: ردگیری کامل یک Job	۲. RDD در لایه‌های زیرین
	۳. گراف DAG: Job، Stage و Task
۵ درس	۳ DataFrame و تبدیل‌ها
۴. گروه‌بندی و تجمیع	۱. ستون‌ها و عبارت‌ها
۵. پروژه‌ی راهنمادار: گزارش منطقه-ساعت در Spark	۲. فیلتر و پاک‌سازی
	۳. Join
۵ درس	۴ Spark SQL و طرح اجرا
۴. توابع تعریف‌شده‌ی کاربر و هزینه‌ی آن‌ها	۱. View موقت و SQL
۵. پروژه‌ی راهنمادار: بهینه‌سازی یک کوئری کند	۲. خواندن خروجی explain()
	۳. بهینه‌سازی‌های Catalyst
۵ درس	۵ پارتیشن، Shuffle و کش
۴. عدم توازن داده و کارهای عقب‌مانده	۱. پارتیشن‌ها
۵. پروژه‌ی راهنمادار: بهینه‌سازی Job منطقه-ساعت	۲. تبدیل‌های باریک و پهن: Shuffle
	۳. کش و ماندگاری
۵ درس	۶ ساخت جریان ETL در Spark
۴. Jobهای تکرارپذیر بدون اثر جانبی	۱. Schemaها
۵. پروژه‌ی راهنمادار: ETL فصلی	۲. خواندن ← پاک‌سازی ← تبدیل
	۳. نوشتن نتایج

۱. قواعد اعتبارسنجی
۲. الگوهای قرنطینه‌ی داده
۳. ثبت ساختاریافته‌ی رویدادها
۴. شکست آشکار و به‌موقع
۵. پروژه‌ی راهنمادار: اجرای ETL همراه با کنترل کیفیت

۱. پروژه‌ی پایانی: جریان Spark عملیاتی شرکت CityFlow

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/contact

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به‌صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.