

پردازش کلان داده با PySpark

PySpark for Data Engineering

یادگیری عملی Apache Spark روی رایانه‌ی شخصی: منطق Spark در Driver، Executor و طرح‌های اجرای Lazy؛ DataFrame و Spark SQL روی ده میلیون سفر واقعی تاکسی؛ طرح اجرا، پارتیشن، Shuffle و کش؛ و یک جریان ETL در قالب محیط عملیاتی با Schema، کنترل کیفیت و ثبت رویداد.

سطح دوره	تعداد بخش‌ها	تعداد درس‌ها	شیوه‌ی برگزاری
متوسط	۸ بخش	۳۶ درس	حضوری یا آنلاین

پیش‌نیازها

- تسلط بر پایتون و pandas
- بهتر است پس از دوره‌ی «پایتون مقیاس‌پذیر برای مهندسی داده» گذرانده شود
- رایانه‌ای که بتواند Spark را به صورت محلی اجرا کند؛ نیازی به خوشه یا حساب ابری نیست

ابزارها و فناوری‌ها

pandas

PySpark (حالت محلی)

PyArrow

پروژه‌ی عملی

جریان کامل ETL با Spark روی داده‌های واقعی تاکسی نیویورک

— آنچه شرکت‌کنندگان می‌آموزند

- ◆ توضیح نقش واقعی Driver، Executor و طرح اجرای Lazy
- ◆ کار با DataFrame و Spark SQL روی ده میلیون رکورد واقعی
- ◆ خواندن طرح اجرا و کنترل پارتیشن‌ها، Shuffle و کش
- ◆ ساخت جریان ETL در قالب محیط عملیاتی با کنترل کیفیت و ثبت رویداد

۵ درس

۱ چرا پردازش توزیع‌شده؟

۱. سقف توان یک رایانه
۲. Driver، Executor و حالت محلی
۳. اولین SparkSession
۴. Spark چه زمانی برتری دارد (و چه زمانی نه)
۵. پروژه‌ی راهنمادار: داده‌ی یک فصل در Spark

۵ درس

۲ Lazy RDD، SparkSession و ارزیابی

۱. تبدیل‌ها در برابر اقدام‌ها
۲. RDD در لایه‌های زیرین
۳. گراف DAG: Job، Stage و Task
۴. تغییرناپذیری و تبارنامه‌ی داده
۵. پروژه‌ی راهنمادار: ردگیری کامل یک Job

۵ درس

۳ DataFrame و تبدیل‌ها

۱. ستون‌ها و عبارت‌ها
۲. فیلتر و پاک‌سازی
۳. Join
۴. گروه‌بندی و تجمیع
۵. پروژه‌ی راهنمادار: گزارش منطقه-ساعت در Spark

۵ درس

۴ Spark SQL و طرح اجرا

۱. View موقت و SQL
۲. خواندن خروجی explain().
۳. بهینه‌سازی‌های Catalyst
۴. توابع تعریف‌شده‌ی کاربر و هزینه‌ی آن‌ها
۵. پروژه‌ی راهنمادار: بهینه‌سازی یک کوئری کند

۵ درس

۵ پارتیشن، Shuffle و کش

۱. پارتیشن‌ها
۲. تبدیل‌های باریک و پهن: Shuffle
۳. کش و ماندگاری
۴. عدم توازن داده و کارهای عقب‌مانده
۵. پروژه‌ی راهنمادار: بهینه‌سازی Job منطقه-ساعت

۵ درس

۶ ساخت جریان ETL در Spark

۱. Schemaها
۲. خواندن ← پاک‌سازی ← تبدیل
۳. نوشتن نتایج
۴. Jobهای تکرارپذیر بدون اثر جانبی
۵. پروژه‌ی راهنمادار: ETL فصلی

۱. قواعد اعتبارسنجی
۲. الگوهای قرنطینه‌ی داده
۳. ثبت ساختاریافته‌ی رویدادها
۴. شکست آشکار و به موقع
۵. پروژه‌ی راهنمادار: اجرای ETL همراه با کنترل کیفیت

۱. پروژه‌ی پایانی: جریان Spark عملیاتی شرکت CityFlow

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/consultation

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.