

پایتون مقیاس‌پذیر برای مهندسی داده

Scaling Python for Data Engineering

پردازش داده‌های بزرگ‌تر از حافظه فقط با پایتون: اندازه‌گیری و کاهش مصرف حافظه با انتخاب نوع داده، بارگذاری فقط داده‌ی موردنیاز، پردازش تکه‌تکه، موازی‌سازی و ساخت ساختمان‌های داده‌ای که جریان‌های واقعی به آن‌ها متکی‌اند؛ همه روی داده‌های واقعی تاکسی‌های نیویورک.

سطح دوره	تعداد بخش‌ها	تعداد درس‌ها	شیوه‌ی برگزاری
مقدماتی تا متوسط	۸ بخش	۳۶ درس	حضوری یا آنلاین

پیش‌نیازها

- تسلط بر پایتون
- آشنایی کاربردی با مبانی pandas: خواندن CSV، انتخاب ستون، گروه‌بندی و تجمیع

ابزارها و فناوری‌ها

NumPy

pandas

Python 3

PyArrow

پروژه‌ی عملی

یک جریان پردازش برای داده‌های بزرگ‌تر از حافظه روی داده‌های تاکسی نیویورک

— آنچه شرکت‌کنندگان می‌آموزند

- ◆ اندازه‌گیری هزینه‌ی واقعی داده در حافظه و کاهش آن با انتخاب نوع داده‌ی مناسب
- ◆ بارگذاری فقط داده‌ی موردنیاز و پردازش تکه‌تکه‌ی داده‌های بزرگ‌تر از حافظه
- ◆ استفاده از NumPy و pandas در مقیاسی که کد ساده دیگر جواب نمی‌دهد
- ◆ موازی‌سازی پردازش روی چند هسته‌ی پردازنده
- ◆ انتخاب ساختمان‌های داده‌ای که جریان‌های واقعی بر پایه‌ی آن‌ها ساخته می‌شوند

۵ درس	۱ وقتی داده از حافظه بزرگ‌تر می‌شود
۱. دیوار حافظه	۴. بارگذاری فقط داده‌ی موردنیاز
۲. سنجش مصرف حافظه و انواع داده	۵. پروژه‌ی راهنمادار: بررسی داده‌های تاکسی نیویورک
۳. جعبه‌ابزار مهندس داده	
۵ درس	۲ NumPy برای مهندسی داده
۱. چرا NumPy	۴. انتشار (Broadcasting)
۲. نوع داده، دقت و حافظه	۵. پروژه‌ی راهنمادار: شاخص‌های سفر با NumPy
۳. برداری‌سازی: از حلقه تا عملیات آرایه‌ای	
۵ درس	۳ pandas در مقیاس بزرگ
۱. کاهش اندازه‌ی نوع داده‌های عددی	۴. گروه‌بندی و تجمیع سریع
۲. داده‌های دسته‌ای (Categorical)	۵. پروژه‌ی راهنمادار: بارگذار کم‌مصرف داده‌های تاکسی
۳. عملیات کارآمد و پرهیز از کپی‌های اضافه	
۵ درس	۴ پردازش تکه‌تکه و فراتر از حافظه
۱. ایده‌ی تکه‌بندی داده	۴. جریان‌های پردازش افزایشی و قابل ازسرگیری
۲. تجمیع جریانی	۵. پروژه‌ی راهنمادار: تجمیع داده‌ی چندماهه‌ای که در حافظه جا نمی‌شود
۳. SQLite به‌عنوان انبار داده‌ی محلی	
۵ درس	۵ پردازش موازی
۱. چرا موازی‌سازی (و قفل سراسری مفسر)	۴. پردازش موازی تکه‌های داده
۲. multiprocessing و Process Pool	۵. پروژه‌ی راهنمادار: تجمیع موازی همراه با اندازه‌گیری
۳. الگوی MapReduce	
۵ درس	۶ ساختمان‌های داده برای کار با داده
۱. دیکشنری و مجموعه: جست‌وجوی $O(1)$ و حذف تکراری‌ها	۴. انتخاب ساختار مناسب
۲. پشته و صف	۵. پروژه‌ی راهنمادار: ایندکس درون‌حافظه‌ای و Top-N
۳. هیپ و صف اولویت	

۱. بازگشت برای پردازش داده
۲. درخت جست و جوی دودویی
۳. درخت برای مرتب سازی و ادغام
۴. ایندکس گذاری یک فایل
۵. پروژهی راهنمادار: ایندکس بازه‌ی زمانی روی داده‌های تاکسی

۱. پروژه‌ی پایانی: جریان تحلیلی برای داده‌های بزرگ‌تر از حافظه

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/consultation

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.