

پایتون مقیاس‌پذیر برای مهندسی داده

Scaling Python for Data Engineering

پردازش داده‌های بزرگ‌تر از حافظه فقط با پایتون: اندازه‌گیری و کاهش مصرف حافظه با انتخاب نوع داده، بارگذاری فقط داده‌ی موردنیاز، پردازش تکه‌تکه، موازی‌سازی و ساخت ساختمان‌های داده‌ای که جریان‌های واقعی به آن‌ها متکی‌اند؛ همه روی داده‌های واقعی تاکسی‌های نیویورک.

سطح دوره	تعداد بخش‌ها	تعداد درس‌ها	شیوه‌ی برگزاری
مقدماتی تا متوسط	۸ بخش	۳۶ درس	حضوری یا آنلاین

پیش‌نیازها

- تسلط بر پایتون
- آشنایی کاربردی با مبانی pandas: خواندن CSV، انتخاب ستون، گروه‌بندی و تجمیع

ابزارها و فناوری‌ها

NumPy

pandas

Python 3

PyArrow

پروژه‌ی عملی

یک جریان پردازش برای داده‌های بزرگ‌تر از حافظه روی داده‌های تاکسی نیویورک

— آنچه شرکت‌کنندگان می‌آموزند

- ◆ اندازه‌گیری هزینه‌ی واقعی داده در حافظه و کاهش آن با انتخاب نوع داده‌ی مناسب
- ◆ بارگذاری فقط داده‌ی موردنیاز و پردازش تکه‌تکه‌ی داده‌های بزرگ‌تر از حافظه
- ◆ استفاده از NumPy و pandas در مقیاسی که کد ساده دیگر جواب نمی‌دهد
- ◆ موازی‌سازی پردازش روی چند هسته‌ی پردازنده
- ◆ انتخاب ساختمان‌های داده‌ای که جریان‌های واقعی بر پایه‌ی آن‌ها ساخته می‌شوند

۵ درس	۱	وقتی داده از حافظه بزرگ‌تر می‌شود
	۱.	دیوار حافظه
	۲.	سنجش مصرف حافظه و انواع داده
	۳.	جعبه‌ابزار مهندس داده
	۴.	بارگذاری فقط داده‌ی موردنیاز
	۵.	پروژه‌ی راهنمادار: بررسی داده‌های تاکسی نیویورک
۵ درس	۲	NumPy برای مهندسی داده
	۱.	چرا NumPy
	۲.	نوع داده، دقت و حافظه
	۳.	برداری‌سازی: از حلقه تا عملیات آرایه‌ای
	۴.	انتشار (Broadcasting)
	۵.	پروژه‌ی راهنمادار: شاخص‌های سفر با NumPy
۵ درس	۳	pandas در مقیاس بزرگ
	۱.	کاهش اندازه‌ی نوع داده‌های عددی
	۲.	داده‌های دسته‌ای (Categorical)
	۳.	عملیات کارآمد و پرهیز از کپی‌های اضافه
	۴.	گروه‌بندی و تجمیع سریع
	۵.	پروژه‌ی راهنمادار: بارگذار کم‌مصرف داده‌های تاکسی
۵ درس	۴	پردازش تکه‌تکه و فراتر از حافظه
	۱.	ایده‌ی تکه‌بندی داده
	۲.	تجمیع جریان‌ی
	۳.	SQLite به‌عنوان انبار داده‌ی محلی
	۴.	جریان‌های پردازش افزایشی و قابل ازسرگیری
	۵.	پروژه‌ی راهنمادار: تجمیع داده‌ی چندماهه‌ای که در حافظه جا نمی‌شود
۵ درس	۵	پردازش موازی
	۱.	چرا موازی‌سازی (و قفل سراسری مفسر)
	۲.	multiprocessing و Process Pool
	۳.	الگوی MapReduce
	۴.	پردازش موازی تکه‌های داده
	۵.	پروژه‌ی راهنمادار: تجمیع موازی همراه با اندازه‌گیری
۵ درس	۶	ساختارهای داده برای کار با داده
	۱.	دیکشنری و مجموعه: جست‌وجوی $O(1)$ و حذف تکراری‌ها
	۲.	پشته و صف
	۳.	هیپ و صف اولویت
	۴.	انتخاب ساختار مناسب
	۵.	پروژه‌ی راهنمادار: ایندکس درون‌حافظه‌ای و Top-N

۱. بازگشت برای پردازش داده
۲. درخت جست و جوی دودویی
۳. درخت برای مرتب سازی و ادغام
۴. ایندکس گذاری یک فایل
۵. پروژهی راهنمادار: ایندکس بازه‌ی زمانی روی داده‌های تاکسی

۱. پروژه‌ی پایانی: جریان تحلیلی برای داده‌های بزرگ‌تر از حافظه

درخواست برگزاری اختصاصی این دوره برای سازمان شما

ثبت درخواست این دوره

lotfinejad.ir/contact

سرفصل، مدت، سطح و تمرین‌های دوره بر اساس نیاز تیم شما تنظیم می‌شود و آموزش به زبان فارسی، به صورت حضوری یا آنلاین برگزار می‌شود. برای ثبت درخواست، فرم مربوط به همین دوره را تکمیل کنید.